



ITESO, Universidad
Jesuita de Guadalajara

Maestría de Ciencia de Datos

Optimización Convexa

Tarea 8: SVR

Estudiante: Daniel Nuño

Profesor: Dr. Juan Diego Sanchez Torres

Fecha entrega: 16 de marzo, 2022

Introduction

For the case of SVM for regression, or SVR, let the set $D = (x_1, y_1), \dots, (x_N, y_N)$, where $x_k \in \mathbb{R}^n$ and $y_k \in \mathbb{R}$. Let $\varphi : X \rightarrow \mathcal{F}$ be the function that makes each input point x correspond a point in the feature space \mathcal{F} , where \mathcal{F} is a Hilbert space. This feature space can be of high dimension or even infinite. However, is common to define $X = \mathbb{R}^n$ and $\mathcal{F} = \mathbb{R}^m$. In this form, the approximating function, namely the model, has the form $\hat{y}_k = f(x_k) = w^T \varphi(x_k) + b$ with $w \in \mathbb{R}^m$ and $b \in \mathbb{R}$.

Commonly, the first approach for solving the SVR is the L_1^ϵ formulation. The following problem statement considers such a regression problem as a convex optimization problem.

Activities

First, the following case considers the application of L_1^ϵ -SVR.

Problem 1: The L_1^ϵ SVR

Consider the following optimization problem:

$$\begin{aligned} \min_{w, b, \xi, \xi^*} \mathcal{P}_\epsilon(w, b, \xi, \xi^*) &= \frac{1}{2} w^T w + c \sum_{k=1}^N (\xi_k + \xi_k^*) \\ \text{s. t. } y_k - w^T \varphi(x_k) - b &\leq \epsilon + \xi_k, \quad k = 1, \dots, N \\ w^T \varphi(x_k) + b - y_k &\leq \epsilon + \xi_k^*, \quad k = 1, \dots, N \\ \xi_k, \xi_k^* &\geq 0, \quad k = 1, \dots, N \end{aligned} \tag{1}$$


where $\varphi(\cdot) : \mathbb{R}^n \rightarrow \mathbb{R}^m$ and the regularization parameter $c > 0$ determines the balance between the regularity of f and the quantity up to which we tolerate deviations more significant than ϵ . Consider ξ_k and ξ_k^* as slack variables that control the error between the prediction \hat{y}_k and the k -th sample y_k .

For this case, present a complete development of the problem (1), by using the KKT optimality approach.

9 marzo, 22

Problema 1: L_1^{ϵ} SVR

considera la siguiente gráfica en 2 dimensiones en la que se quiere plantear una regresión lineal



$$y_k - w^T p(x_k) - b \rightarrow \text{Ariba}$$

$$w^T p(x_k) + b - y_k \rightarrow \text{Abaja}$$

E es la diferencia entre la línea sólida y la línea punteada.

error es el valor entre cada punto y la línea sólida.

ξ es el error en cada punto por afuera de la línea punteada.

Los vectores de soporte son los que estan por afuera del tubo.

El problema se vuelve relevante solo a los valores que estan por afuera del tubo.

primero definimos Lagrange como

$L(w, b, \xi, \xi^*, \alpha, \alpha^*, \eta, \eta^*)$ siendo $\alpha, \alpha^*, \eta, \eta^*$ los valores de Lagrange

$$= \frac{1}{2} w^T w + c \sum (\xi_k + \xi_k^*) - \sum \alpha_k (E + \xi_k - y_k - w^T p(x_k) + b)$$

$$- \sum \alpha_k^* (E + \xi_k^* - y_k - w^T p(x_k) - b + y_k)$$

$$- \sum \eta_k \xi_k$$

$$- \sum \eta_k^* \xi_k^*$$

Usamos KKT1, derivamos respecto las variables del primal e igualamos a cero

$$\nabla W = w - \sum \alpha_k p(x_k) + \sum \alpha_k^* p(x_k) = 0$$

$$w = \sum \alpha_k p(x_k) - \sum \alpha_k^* p(x_k)$$

$$\frac{\partial L}{\partial b} = \sum \alpha_k + \sum \alpha_k^* = 0$$

$$\sum (\alpha_k + \alpha_k^*) = 0$$

$$\frac{\partial L}{\partial \xi_k^*} = C - \alpha_k^* - \eta_k^* = 0$$

$$C - \alpha_k^* = \eta_k^*$$

$$\frac{\partial L}{\partial \xi_k} = C - \alpha_k - \eta_k = 0$$

$$C - \alpha_k = \eta_k$$

Ahora simplificamos y escribimos el dual

$$L = \frac{1}{2} W^T W + C \sum (\xi_k + \xi_k^*) = C \sum (\alpha_k + \alpha_k^*) - \sum \alpha_k \xi_k$$

$$- \sum \alpha_k^* \xi_k^* + \sum (\alpha_k - \alpha_k^*) y_k - \sum (\alpha_k - \alpha_k^*) W^T \phi(x_k)$$

$$- b \sum (\alpha_k + \alpha_k^*) - C \sum (\xi_k + \xi_k^*) + \sum \alpha_k \xi_k + \sum \alpha_k^* \xi_k^*$$

Lagrange Dual se escribe como

$$D = \frac{1}{2} \sum_{i=1}^N \sum_{k=1}^N (\alpha_i - \alpha_i^*) (\alpha_k - \alpha_k^*) \phi(x_i)^T \phi(x_k) + \sum (\alpha_k + \alpha_k^*) y_k$$

$$- C \sum (\alpha_k + \alpha_k^*)$$

siendo el dual que busca maximizar α_k y α_k^*

$$\max_{\alpha_k, \alpha_k^*} D = \frac{1}{2} \sum \sum (\alpha_i - \alpha_i^*) (\alpha_k - \alpha_k^*) \phi(x_i)^T \phi(x_k) + \sum (\alpha_k + \alpha_k^*) y_k - C \sum (\alpha_k + \alpha_k^*)$$

$$s.t. \sum (\alpha_k + \alpha_k^*) = 0 \quad 0 \leq \alpha_k \leq C$$

$$\eta_k = C - \alpha_k, \quad \eta_k \geq 0$$

$$C - \alpha_k \geq 0$$

$$C \geq 0$$

9 marzo, 22.

KKT2 son las restricciones del primal

$$y_k - W^T p(x_k) - b \leq \epsilon + \xi_k$$

$$W^T p(x_k) + b - y_k \leq \epsilon + \xi_k^*$$

$$\xi_k \geq 0$$

$$\xi_k^* \geq 0$$

KKT3 son las restricciones del dual

$$\sum_{k=1}^N (\alpha_k - \alpha_k^*) = 0$$

$$0 \leq \alpha_k \leq C$$

$$0 \leq \alpha_k^* \leq C$$

KKT4 son las restricciones KKT2 y KKT3 más la condición complementaria

$$\eta_k \xi_k = 0 \quad \text{condiciones complementarias}$$

$$\eta_k^* \xi_k^* = 0$$

$$\alpha_k (y_k - W^T p(x_k) - b - \epsilon - \xi_k) = 0$$

$$\xi_k \geq 0$$

$$\eta_k = C - \alpha_k$$

los siguientes casos son para ξ_k , o sea para cuando esta arriba de la η_k
Para el caso 1: $\alpha_k = 0 \Rightarrow \eta_k = C \Rightarrow \xi_k = 0$

$$y_k - W^T p(x_k) - b \leq \epsilon$$

esta dentro del tubo, entre las dos líneas punteadas y no le aparta al modelo

9 marzo, 22

Caso 2: $0 \leq \alpha_k \leq C$

$$y_k - w^T p(x_k) - b = \epsilon$$

Los vectores están sobre del tubo punteado

Caso 3: $\alpha_k = C \Rightarrow \eta_k = 0 \Rightarrow \xi_k > 0$

$$y_k - w^T p(x_k) - b < \epsilon + \xi_k$$

está por afuera del tubo punteado

Finally, the following case considers the application of L_2^ϵ -SVR.

Problem 2: The L_2^ϵ SVR

Consider the following optimization problem:

$$\begin{aligned} \min_{w, b, \zeta, \zeta^*} \mathcal{P}_\epsilon(w, b, \zeta, \zeta^*) &= \frac{1}{2} w^T w + \frac{c}{2} \sum_{k=1}^N (\zeta_k^2 + \zeta_k^{*2}) \\ \text{s. t. } y_k - w^T \varphi(x_k) - b &\leq \epsilon + \zeta_k, \quad k = 1, \dots, N \\ w^T \varphi(x_k) + b - y_k &\leq \epsilon + \zeta_k^*, \quad k = 1, \dots, N \end{aligned} \quad (2)$$

where $\varphi(\cdot) : \mathbb{R}^n \rightarrow \mathbb{R}^m$ and the regularization parameter $c > 0$ determines the balance between the regularity of f and the quantity up to which we tolerate deviations more significant than ϵ . Consider ζ_k and ζ_k^* as slack variables that control the error between the prediction \hat{y}_k and the k -th sample y_k .

For this case, present a complete development of the problem (2), by using the KKT optimality approach.

16 marzo, 22

Problema 2: L2 SVR L2 soft-margin SVR

En el problema 1 utilizamos la función de pérdida L1.

Ahora vamos a usar L2 que indica errores menores al cuadrado que se relacionan a la norma 1 y norma 2

A esta formulación de SVR se le conoce como squared epsilon insensitive, la zona insensitiva es epsilon dentro de las líneas punteadas

primero definimos el lagrange del dual como

$$L(W, b, \xi_k, \xi_k^*, \alpha_k^*, \alpha_k, A, A^*) \quad \text{siendo } \alpha, \alpha^*, A, A^* \text{ los valores de lagrange}$$

$$= \frac{1}{2} W^T W + \frac{C}{2} \sum (\xi_k^2 + \xi_k^{*2}) - \sum \alpha_k (E + \xi_k - y_k + W^T p(x_k) + b) - \sum \alpha_k^* (E + \xi_k^* - W^T p(x_k) - b + y_k)$$

(I)

Como ξ_k y ξ_k^* estan al cuadrado en el primal, no estan restringidos a la condición $\xi_k \geq 0$, $\xi_k^* \geq 0$. Por lo tanto eliminamos los multiplicadores de lagrange asociados.

Ahora derivamos e igualamos a cero.

$$\frac{\partial L}{\partial W} = \nabla W = W - \sum (\alpha_k - \alpha_k^*) p(x_k) = 0 \quad \text{(II)}$$

$$W = \sum (\alpha_k - \alpha_k^*) p(x_k)$$

$$\frac{\partial L}{\partial b} = \sum (\alpha_k^* - \alpha_k) = 0 \quad \text{(III)}$$

$$\frac{\partial L}{\partial \xi_k} = C \xi_k - \alpha_k = 0 \quad \text{(IV)}$$

$$\frac{\partial L}{\partial \xi_k^*} = C \xi_k^* - \alpha_k^* = 0 \quad \text{(V)}$$

16 marzo, 20
Sustituyendo y simplificando II, III, IV y V en I obtenemos el dual

$$\text{Max}_{\alpha, \alpha^*} = \frac{1}{2} \sum \sum (\alpha_i - \alpha_i^*) (\alpha_k - \alpha_k^*) p(x_k)^T p(x_k)$$

$$- \epsilon \sum (\alpha_k + \alpha_k^*) + \sum \gamma_k (\alpha_k - \alpha_k^*) \quad \text{VI}$$

$$\text{s.t. } \sum (\alpha_k - \alpha_k^*) = 0$$

$$\alpha_k \geq 0 \quad \text{para } k=1, \dots, N$$

$$\alpha_k^* \geq 0 \quad \text{para } k=1, \dots, N$$

Más aún podemos definir $K(x_k, x) = p(x_k)^T p(x)$

$$\text{e introducir } F(x) = \sum (\alpha_k - \alpha_k^*) K(x_k, x) + b \quad \text{VII}$$

$$\text{donde } \sum (\alpha_k - \alpha_k^*) p(x_k) = w \quad \text{⑩}$$

Abe define el dual como

$$\frac{1}{2} \sum_{k=1}^N \sum_{i=1}^N (\alpha_k - \alpha_k^*) (\alpha_i - \alpha_i^*) \left(K(x_k, x_i) + \frac{\delta_{k,i}}{\epsilon} \right)$$

$$- \epsilon \sum_{k=1}^N (\alpha_k + \alpha_k^*) + \sum_{k=1}^N (\alpha_k - \alpha_k^*) \gamma_k$$

donde $\delta_{k,i}$ es la función delta de Kronecker

La solución óptima debe satisfacer las siguientes condiciones complementarias

KKT4

$$\alpha_k (\epsilon + \epsilon_k - \gamma_k + w^T p(x_k) + b) = 0 \quad \text{para } k=1, \dots, N$$

$$\alpha_k^* (\epsilon + \epsilon_k^* + \gamma_k - w^T p(x_k) - b) = 0 \quad \text{para } k=1, \dots, N$$

$$\epsilon \epsilon_k = \alpha_k, \quad \epsilon \epsilon_k^* = \alpha_k^* \quad \text{para } k=1, \dots, N$$

Caso 1: $\alpha_k = 0$, $\alpha_k^* = 0$

16 marzo, 22

Todo b de dentro de la función no importa por que
esta multiplicado por 0.

Satisface $|y - f(x)| < \epsilon$ y estos vectores no contribuyen
a la construcción del modelo

Caso 2: $\alpha_k > 0$, $\alpha_k^* > 0$

$$b = y_k - w^T \phi(x_k) - \epsilon - \frac{\alpha_k}{C} \quad \text{para } \alpha_k > 0$$

$$b = y_k - w^T \phi(x_k) + \epsilon + \frac{\alpha_k^*}{C} \quad \text{para } \alpha_k^* > 0$$

estas son los vectores de soporte.

L2 no tiene vectores de soporte restringidos y la matriz
Hessiana es definida positiva.